Proyek Akhir Data Warehouse
Perancangan Data Warehouse dan Data Mart untuk Analisis Penjualan E-Commerce Menggunakan Atoti OLAP

Nagatan Alief Putra Silahen (24031554086), Muslim Fazlur Rohman (24031554154), Muhammad Ramadhan Albaary Putra (24031554161), Kafka Praya Firmansyah (24031554182)
Kelas 2024C
Dosen Pengampu Mata Kuliah: Harmon Prayogi, M.Sc.

BAB 1 Pendahuluan

A. Latar Belakang

Perkembangan teknologi informasi telah mendorong pertumbuhan bisnis e-commerce yang menghasilkan data dalam jumlah besar setiap harinya. Data tersebut berasal dari berbagai aktivitas bisnis, seperti transaksi penjualan, pembayaran, pengiriman, produk, pelanggan, dan penjual. Meskipun memiliki potensi besar untuk mendukung pengambilan keputusan, data operasional sering kali tersimpan pada berbagai tabel yang terpisah sehingga proses analisis menjadi lebih kompleks dan memerlukan penggabungan data secara berulang. Menurut Akter dan Wamba (2016), sektor e-commerce sangat bergantung pada pemanfaatan data analytics karena menghasilkan data yang beragam dan terus berkembang. Pada dataset yang digunakan dalam penelitian ini, data utama terdiri dari *customers, orders, order_items, payments, products,* dan *sellers* yang saling berhubungan dalam mendukung proses transaksi e-commerce. Meskipun data tersebut telah merepresentasikan aktivitas bisnis secara lengkap, informasi yang dibutuhkan manajemen belum dapat diperoleh secara langsung karena data masih tersebar pada berbagai tabel operasional. Selain permasalahan integrasi data, masih ditemukan beberapa masalah kualitas data seperti *missing value* pada atribut tertentu yang berpotensi memengaruhi akurasi hasil analisis. Ren et al. (2017) menyatakan bahwa kualitas data dan kualitas sistem berperan penting dalam menghasilkan informasi yang bernilai bagi organisasi.

Untuk mengatasi permasalahan tersebut, diperlukan pembangunan Data Warehouse (DW) yang mampu mengintegrasikan data dari berbagai sumber ke dalam satu repositori terpusat melalui proses *Extract, Transform, Load* (ETL). Kathiravelu et al. (2018) menjelaskan bahwa proses ETL membantu menghasilkan data yang lebih terstruktur dan siap digunakan untuk kebutuhan analisis. Berdasarkan kondisi tersebut, rumusan masalah penelitian ini adalah bagaimana membangun Data Warehouse yang mampu mengintegrasikan data e-commerce secara konsisten serta meningkatkan kualitas data untuk mendukung analisis bisnis. Adapun tujuan penelitian ini adalah membangun Data Warehouse yang dapat menyediakan informasi mengenai total penjualan, jumlah transaksi, performa produk, kontribusi penjual, distribusi metode pembayaran, dan tren penjualan berdasarkan waktu secara terstruktur. Manfaat yang diharapkan yaitu mempercepat proses pelaporan, meningkatkan kualitas informasi untuk pengambilan keputusan, serta menjadi fondasi bagi penerapan *Business Intelligence*. Hal ini sejalan dengan penelitian Gunasekaran et al. (2017) yang menunjukkan bahwa pemanfaatan data analytics yang terintegrasi dapat meningkatkan efektivitas pengambilan keputusan dan kinerja organisasi.

B. Rumusan Masalah Penelitian

1. Bagaimana mengintegrasikan data *customers, orders, order_items, payments, products,* dan *sellers* ke dalam sebuah Data Warehouse yang terstruktur dan terpusat?
2. Bagaimana menerapkan proses *Extract, Transform, Load* (ETL) untuk meningkatkan kualitas, konsistensi, dan kesiapan data sebelum digunakan untuk analisis bisnis?
3. Bagaimana membangun Data Warehouse yang mampu menyediakan informasi mengenai total penjualan, jumlah transaksi, performa produk, kontribusi penjual, distribusi metode pembayaran, dan tren penjualan guna mendukung pengambilan keputusan bisnis?

C. Tujuan Penelitian

1. Membangun Data Warehouse yang mampu mengintegrasikan data *customers, orders, order_items, payments, products,* dan *sellers* ke dalam satu repositori data yang terstruktur dan terpusat.
2. Menerapkan proses *Extract, Transform, Load* (ETL) untuk meningkatkan kualitas, konsistensi, dan kesiapan data sehingga dapat digunakan untuk kebutuhan analisis bisnis.
3. Menyediakan informasi bisnis mengenai total penjualan, jumlah transaksi, performa produk, kontribusi penjual, distribusi metode pembayaran, dan tren penjualan berdasarkan waktu guna mendukung pengambilan keputusan dan penerapan *Business Intelligence*.

D. Manfaat Penelitian

1. Membantu mengintegrasikan data *customers, orders, order_items, payments, products,* dan *sellers* ke dalam satu sumber data yang terpusat sehingga memudahkan proses pengelolaan dan analisis data.
2. Meningkatkan kualitas dan konsistensi data melalui proses *Extract, Transform, Load* (ETL) sehingga informasi yang dihasilkan lebih akurat dan dapat dipercaya.
3. Mempermudah penyediaan informasi mengenai total penjualan, jumlah transaksi, performa produk, kontribusi penjual, distribusi metode pembayaran, dan tren penjualan untuk mendukung pengambilan keputusan bisnis.
4. Mempercepat proses pembuatan laporan dan analisis data dibandingkan dengan penggunaan data operasional yang tersebar pada banyak tabel.
5. Menjadi fondasi dalam penerapan *Business Intelligence* untuk membantu perusahaan memantau kinerja bisnis dan menyusun strategi pengembangan usaha berdasarkan data.

BAB 2 Desain Star Schema

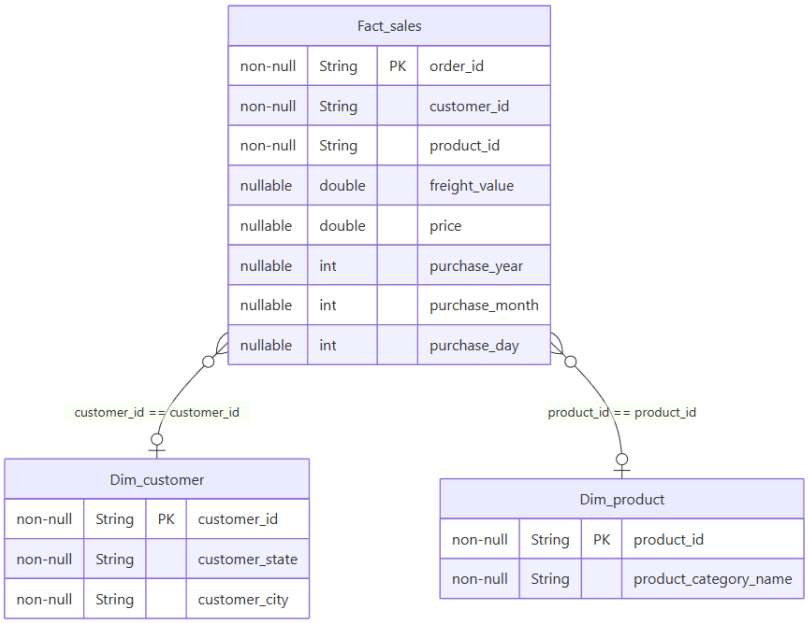
A. Konsep Star Schema

Desain star schema dibangun menggunakan pendekatan data mart. Pendekatan ini dipilih karena setiap kebutuhan analisis memiliki fokus data yang berbeda sehingga struktur schema dipisahkan sesuai domain analisis masing-masing. Data mart yang dibangun terdiri atas Sales Mart, Product Mart, dan Logistic Mart.

Setiap data mart memiliki fact table dan dimension table tersendiri yang disesuaikan dengan kebutuhan. Sales Mart digunakan untuk analisis transaksi penjualan, Product Mart digunakan untuk analisis produk dan kategori produk, sedangkan Logistic Mart digunakan untuk analisis data pengiriman.

Dengan pendekatan data mart, proses analisis menjadi lebih terstruktur karena setiap schema hanya memuat atribut yang relevan terhadap kebutuhan analisis tertentu.

B. Star Schema Sales Mart



Gambar 1. Star Schema Sales Mart

Sales Mart dirancang untuk mendukung analisis penjualan dan perilaku pelanggan. Fokus utama data mart ini adalah pengukuran revenue transaksi, distribusi pelanggan berdasarkan wilayah, serta analisis kategori produk yang berkontribusi terhadap penjualan. Struktur Sales Mart terdiri atas satu fact table yaitu Fact_sales dan dua dimension table yaitu Dim_customer dan Dim_product.

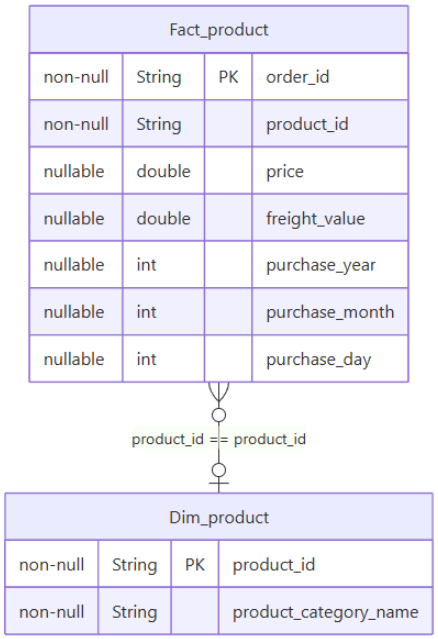
Fact_sales merupakan tabel fakta utama yang menyimpan data transaksi penjualan. Granularitas pada fact table ini berada pada level transaksi order-item. Artinya, setiap baris data merepresentasikan satu produk yang dibeli pelanggan pada suatu transaksi tertentu. Atribut price dan freight_value disimpan sebagai atribut numerik pada fact table karena merepresentasikan nilai transaksi dan biaya pengiriman pada setiap order-item. atribut waktu seperti purchase_year, purchase_month, dan purchase_day ditambahkan untuk mempertahankan informasi waktu sehingga data dapat dikelompokkan berdasarkan periode waktu tertentu pada proses analisis OLAP.

Dim_customer dan Dim_product merupakan dimensional tabel. Dim_customer digunakan untuk menyimpan atribut pelanggan yang digunakan pada analisis wilayah pelanggan. Sedangkan Dim_product digunakan untuk menyimpan informasi kategori produk.

Relasi pada Sales Mart menggunakan hubungan one to many. Tabel Dim_customer terhubung ke Fact_sales melalui atribut customer_id, sedangkan tabel Dim_product

terhubung ke Fact_sales melalui atribut product_id.

C. Star Schema Product Mart



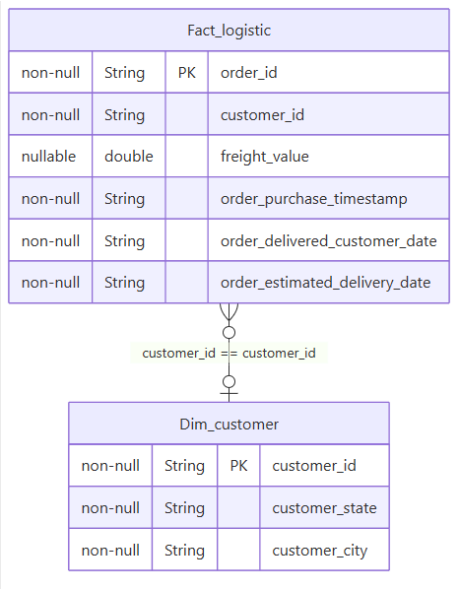
Gambar 2. Star Schema Product Mart

Product Mart dibuat untuk analisis performa produk dan kategori produk pada platform e-commerce. Data mart ini digunakan untuk mengevaluasi kontribusi produk terhadap revenue perusahaan serta memahami pola penjualan berdasarkan kategori barang. Product Mart terdiri atas satu fact table yaitu Fact_product dan satu dimension table yaitu Dim_product.

Fact_product menyimpan data transaksi produk. Granularitas fact table berada pada level produk per transaksi. Atribut waktu pada fact table digunakan untuk mempertahankan informasi tanggal transaksi hasil transformasi timestamp pada proses ETL.

Dimensional tabel data mart ini adalah Dim_product yang digunakan untuk menyimpan kategori produk. Relasi one to many antara Fact_product dan Dim_product dilakukan menggunakan atribut product_id.

D. Star Schema Logistic Mart



Gambar 3. Star Schema Logistic Mart

Logistic Mart digunakan untuk menyimpan data yang berkaitan dengan pengiriman transaksi pelanggan. Logistic Mart terdiri atas satu fact table yaitu Fact_logistic dan satu dimension table yaitu Dim_customer.

Fact_logistic menyimpan data yang berkaitan dengan pengiriman transaksi pelanggan. Granularitas fact table berada pada level transaksi pengiriman individual. Setiap baris data merepresentasikan satu transaksi pengiriman pelanggan. Atribut timestamp digunakan untuk melihat informasi waktu pembelian, waktu barang diterima pelanggan, dan estimasi pengiriman.

Dimensional tabel dari data mart ini adalah Dim_customer yang digunakan untuk menyimpan informasi wilayah pelanggan. Atribut wilayah pelanggan digunakan karena data pengiriman dapat dikelompokkan berdasarkan lokasi pelanggan. Relasi one to many antara Fact_logistic dan Dim_customer dilakukan melalui atribut customer_id.

BAB 3 Proses ETL

A. Penjelasan Dataset

Penelitian ini menggunakan dataset Olist E-Commerce yang berisi data transaksi penjualan dari platform e-commerce di Brazil. Dataset terdiri dari beberapa tabel yang saling berhubungan dan digunakan sebagai sumber utama dalam pembangunan data warehouse. Tabel yang digunakan pada penelitian ini meliputi tabel customers, orders, order_items, payments, products, dan sellers.

B. Extract

Tahap extract dilakukan dengan membaca file CSV menggunakan Python dan library Pandas. Dataset yang digunakan terdiri dari tabel customers, orders, order_items, order_payments, products, dan sellers.

Setelah data dibaca, dilakukan pengecekan jumlah baris, jumlah kolom, tipe data, nilai kosong, dan duplikasi. Pengecekan ini penting agar masalah pada data dapat diketahui sebelum data dimasukkan ke data warehouse.

C. Inventaris Masalah Data

Berikut adalah ringkasan masalah data yang ditemukan pada tahap awal.

Tabel	Kolom Bermasalah	Jenis Masalah	Jumlah Masalah	Penanganan
Orders	order_approved_at	Nilai Kosong	160	Diisi berdasarkan rata-rata selisih waktu approval
Orders	order_delivered_carrier_date	Nilai Kosong	1783	Diisi berdasarkan rata-rata selisih waktu ke carrier
Orders	order_delivered_customer_date	Nilai Kosong	2965	Diisi berdasarkan rata-rata selisih waktu pengiriman ke customer
Products	product_category_name	Nilai Kosong	610	Diisi dengan kategori unknown
Products	product_name_lenght	Nilai Kosong	610	Diisi dengan nilai mean
Products	product_description_lenght	Nilai Kosong	610	Diisi dengan nilai median
Products	product_photos_qty	Nilai Kosong	610	Diisi dengan nilai median
Products	product_weight_g, product_length_cm,	Nilai Kosong	2	Baris dihapus karena

	product_height_cm, product_width_cm			jumlahnya sangat kecil
Sellers	seller_city	Inkonsistensi Penulisan	Beberapa nilai	Diseragamkan menggunakan mapping manual
Semua Tabel Utama	Primary key	Duplikasi	Tidak ditemukan	Data dipertahankan

Tabel 1. Ringkasan Hasil Permasalahan dan Data Cleaning

D. Transform

Pada tahap transform dilakukan untuk membersihkan dan menyesuaikan data agar siap digunakan dalam data warehouse.

1. Penanganan Nilai Kosong pada Produk

   Pada tabel products, terdapat nilai kosong pada kategori produk dan beberapa atribut produk. Kolom *product_category_name* diisi dengan nilai unknown agar produk yang kategorinya belum diketahui tetap bisa dianalisis. Untuk kolom numerik seperti product_description_lenght dan product_photos_qty, digunakan median karena median lebih aman jika data memiliki nilai ekstrem. Sedangkan *product_name_lenght* diisi dengan mean karena nilai panjang nama produk masih dapat dirata-ratakan. Setelah proses ini, tabel products tidak memiliki nilai kosong lagi dan jumlah data akhir menjadi 32.949 baris.

2. Penanganan Nilai Kosong pada Tanggal Order

   Pada tabel orders, terdapat nilai kosong pada tanggal approval, tanggal dikirim ke carrier, dan tanggal diterima customer. Nilai kosong ini tidak langsung dihapus karena jumlahnya cukup banyak dan masih berhubungan dengan data transaksi. Jika semua baris kosong dihapus, maka sebagian informasi transaksi akan hilang. Penanganannya dilakukan dengan menghitung rata-rata selisih waktu antar proses, yaitu:

Proses	**Rata-Rata Selisih**
Dari pembelian ke approval	Sekitar 10 jam 25 menit
Dari approval ke carrier	Sekitar 2 hari 19 jam
Dari carrier ke customer	Sekitar 9 hari 7 jam

Tabel 2. Rata-Rata Durasi Antar Tahapan Proses Order

   Nilai kosong kemudian diisi menggunakan estimasi berdasarkan rata-rata selisih tersebut. Dengan cara ini, data tanggal tetap masuk akal karena mengikuti pola waktu dari data yang sudah lengkap.

3. Perubahan Tipe Data Tanggal

   Kolom tanggal pada tabel orders awalnya bertipe object/string. Kolom tersebut diubah menjadi tipe datetime agar dapat digunakan untuk analisis waktu.
   Contoh kolom yang diubah:

   order_purchase_timestamp

order_approved_at
order_delivered_carrier_date
Order_delivered_customer_date

Setelah menjadi datetime, kolom waktu dapat dipecah menjadi tahun, bulan, hari, jam, menit, dan detik. Pemecahan ini berguna untuk membangun hierarchy waktu pada OLAP cube.

4. Penanganan Inkonsistensi Kategorik pada Seller
   Pada tabel sellers, ditemukan beberapa penulisan kota yang tidak konsisten, misalnya:

Nilai Awal	**Nilai Setelah Dibersihkan**
sao paulo / sao paulo	sao paulo
sp / sp	sao paulo
sp	sao paulo
sao paulo - sp	sao paulo
rio de janeiro / rio de janeiro	rio de janeiro
04482255	unknown
vendas@creditparts.com.br	unknown

Tabel 3. Hasil Penanganan Inkonsistensi Penulisan Data

Pembersihan ini dilakukan agar analisis berdasarkan kota seller tidak terpecah karena perbedaan penulisan. Misalnya, sao paulo, sp, dan sao paulo - sp sebenarnya merujuk ke lokasi yang sama, sehingga harus diseragamkan.

E. Validasi Hasil Transformasi

Setelah transformasi selesai, dilakukan pengecekan ulang terhadap nilai kosong dan duplikasi. Hasil validasi menunjukkan bahwa data yang digunakan untuk proses load sudah lebih bersih dan siap dimasukkan ke data warehouse.

Validasi	**Hasil**
Duplikasi pada primary key customer	Tidak ditemukan
Duplikasi pada primary key order	Tidak ditemukan
Duplikasi pada primary key product	Tidak ditemukan
Nilai kosong pada products	Sudah ditangani
Nilai kosong pada orders	Sudah ditangani
Tipe data tanggal	Sudah diubah menjadi datetime
Inkonsistensi kota seller	Sudah diseragamkan

Tabel 4. Hasil Validasi Data Setelah Proses Transformasi

F. LOAD

Tahap load dilakukan dengan menyimpan data yang sudah dibersihkan ke dalam database relasional. Pada proyek ini, database yang digunakan adalah SQLite sebagai database lokal karena lebih ringan dan mudah digunakan di Jupyter Notebook. Walaupun menggunakan SQLite, struktur tabel tetap berbasis SQL sehingga masih bisa dipindahkan ke PostgreSQL jika dibutuhkan.

Tabel yang dimuat ke database adalah *customers, orders, order_items, payments, products, dan sellers*. Proses load dilakukan agar data hasil transformasi tidak hanya tersimpan sebagai dataframe, tetapi juga bisa digunakan untuk query SQL, data mart, dan pembuatan OLAP cube.

Contoh proses load:

```
customers.to_sql("customers", dw, if_exists="replace", index=False)
orders.to_sql("orders", dw, if_exists="replace", index=False)
order_items.to_sql("order_items", dw, if_exists="replace", index=False)
payments.to_sql("payments", dw, if_exists="replace", index=False)
products.to_sql("products", dw, if_exists="replace", index=False)
sellers.to_sql("sellers", dw, if_exists="replace", index=False)
```

Parameter *if_exists="replace"* digunakan agar tabel lama diganti dengan tabel baru yang sudah dibersihkan. Sementara itu, *index=False* digunakan agar index dataframe tidak ikut masuk sebagai kolom tambahan di database.

Setelah proses load, tabel yang sudah masuk ke database dapat dicek menggunakan query :

```
pd.read_sql("""
SELECT name
FROM sqlite_master
WHERE type='table';
""", dw)
```

Dari proses ini, seluruh tabel utama berhasil dimuat ke database dan siap digunakan untuk tahap berikutnya, yaitu pembuatan data warehouse, data mart, dan OLAP cube.

BAB 4 Custom Measures dan Data Mart

A. Custom Measure

Custom Measures digunakan untuk menghasilkan indikator kinerja utama (*Key Performance Indicator/ KPI*) yang dapat membantu proses analisis bisnis pada data e-commerce. Pada implementasi menggunakan Atoti, beberapa measure dibuat berdasarkan data transaksi pada tabel *order_items* dan *orders*. Measure yang digunakan meliputi Revenue, Total Freight, Total Order, dan Average Revenue. Hasil agregasi menunjukkan total pendapatan (*Revenue*) sebesar 13.591.643,70 dan total pesanan (*Total Order*) sebanyak 98.666 transaksi.

Measure	**Formula**	**Interpretasi**
Revenue	SUM(price)	Total nilai penjualan seluruh produk yang berhasil terjual.
Total Freight	SUM(freight_value)	Total biaya pengiriman yang dibayarkan pelanggan.
Total Order	COUNT DISTINCT(order_id)	Jumlah transaksi unik yang terjadi pada sistem.
Average Revenue	AVG(price)	Rata-rata nilai penjualan per item produk yang terjual.

Tabel 5. Formula dan Interpretasi Custom Measure

Analisis terhadap custom measures menunjukkan bahwa *Revenue* digunakan sebagai indikator utama untuk mengukur total pendapatan yang dihasilkan dari seluruh transaksi penjualan. *Total Freight* digunakan untuk mengetahui besarnya biaya pengiriman yang dikeluarkan dalam proses distribusi produk kepada pelanggan. Sementara itu, *Total Order* menggambarkan jumlah transaksi yang berhasil dilakukan sehingga dapat digunakan untuk melihat tingkat aktivitas pembelian pada platform e-commerce. Selain itu, *Average Revenue* menunjukkan rata-rata pendapatan yang diperoleh dari setiap item produk yang terjual. Kombinasi keempat measure tersebut memungkinkan perusahaan untuk memantau performa penjualan, aktivitas transaksi, serta efisiensi biaya logistik secara lebih menyeluruh dalam mendukung pengambilan keputusan bisnis.

B. Hierarki

Hierarki digunakan untuk mengelompokkan data ke dalam beberapa level sehingga proses analisis dapat dilakukan dari tingkat yang lebih umum hingga tingkat yang lebih rinci. Pada Data Warehouse ini, hierarki dibangun berdasarkan dimensi lokasi, waktu, dan produk untuk mendukung analisis multidimensi pada cube yang telah dibuat.

Hierarki	**Level Hierarki**	**Fungsi**
Geography Seller	seller_state → seller_city	Digunakan untuk

		menganalisis persebaran penjual berdasarkan wilayah geografis
Purchase Time	purchase_year → purchase_month → purchase_day → purchase_hour → purchase_minute → purchase_second	Digunakan untuk menganalisis transaksi berdasarkan waktu pembelian secara detail
Approve Time	approve_year → approve_month → approve_day → approve_hour → approve_minute → approve_second	Digunakan untuk menganalisis waktu persetujuan pesanan setelah transaksi dilakukan
Carrier Time	carrier_year → carrier_month → carrier_day → carrier_hour → carrier_minute → carrier_second	Digunakan untuk menganalisis waktu pengiriman pesanan kepada pihak kurir
Customer Time	customer_year → customer_month → customer_day → customer_hour → customer_minute → customer_second	Digunakan untuk menganalisis waktu pesanan diterima oleh pelanggan
Geography Customer	customer_state → customer_city	Digunakan untuk menganalisis persebaran pelanggan berdasarkan wilayah geografis
Product	product_category_name → product_id	Digunakan untuk menganalisis performa penjualan berdasarkan kategori produk maupun produk secara spesifik

Tabel 6. Hierarki Dimensi pada Cube OLAP

Berdasarkan hierarki yang dibangun, Data Warehouse telah mendukung analisis berdasarkan lokasi, waktu, dan produk. Hierarki *Geography Seller* dan *Geography Customer* memungkinkan analisis persebaran penjual maupun pelanggan berdasarkan wilayah, sedangkan hierarki *Product* memungkinkan analisis dilakukan mulai dari kategori produk hingga produk secara spesifik. Melalui hierarki tersebut, perusahaan dapat mengidentifikasi wilayah dan produk yang memberikan kontribusi terbesar terhadap penjualan.

Selain itu, hierarki *Purchase Time, Approve Time, Carrier Time, dan Customer Time* memungkinkan analisis dilakukan pada setiap tahapan transaksi dan pengiriman.

Hierarki ini membantu perusahaan dalam mengidentifikasi pola transaksi berdasarkan waktu, mengevaluasi proses pemrosesan pesanan, serta memantau aktivitas pengiriman hingga produk diterima oleh pelanggan. Secara keseluruhan, hierarki yang dibangun mendukung proses *drill-down* dan *roll-up* sehingga analisis dapat dilakukan secara lebih fleksibel sesuai kebutuhan bisnis.

C. Data Mart

Untuk mendukung kebutuhan analisis yang lebih spesifik, Data Warehouse yang dibangun dibagi menjadi tiga Data Mart, yaitu *Sales Mart, Product Mart, dan Logistic Mart*. Pembagian ini dilakukan agar setiap area bisnis dapat dianalisis secara lebih terfokus sesuai kebutuhan pengguna. Masing-masing Data Mart dibangun menggunakan kombinasi tabel fakta dan tabel dimensi yang berasal dari proses ETL pada data transaksi e-commerce.

1. Sales Mart

Sales Mart digunakan untuk mendukung analisis penjualan dengan mengintegrasikan data transaksi, pelanggan, produk, dan waktu pembelian. Data mart ini membantu perusahaan dalam memantau performa penjualan, mengidentifikasi pola transaksi pelanggan, serta mengevaluasi kontribusi produk terhadap pendapatan perusahaan. Sales Mart dibangun menggunakan tabel fakta *fact_sales* dan tabel dimensi *dim_customer* serta *dim_product*.

Berikut adalah contoh query sql pada Sales Mart:

```
query_sales = """
    select
        oi.order_id,
        c.customer_id,
        p.product_id,
        oi.freight_value,
        oi.price,
        o.purchase_year,
        o.purchase_month,
        o.purchase_day
    from order_items oi
    join orders o
        on oi.order_id = o.order_id
    join customers c
        on o.customer_id = c.customer_id
    join products p
        on oi.product_id = p.product_id;
"""

fact_sales = pd.read_sql(query_sales, dw)
fact_sales.head()
```

Query diatas digunakan untuk menggabungkan data dari tabel *order_items*, *orders*, *customers*, dan *products* melalui proses *join*. Hasil penggabungan ini membentuk tabel fakta (*fact_sales*) yang berisi informasi transaksi penjualan, seperti identitas pesanan, pelanggan, produk yang dibeli, biaya pengiriman, harga produk, serta waktu pembelian. Dengan mengintegrasikan data yang sebelumnya tersebar pada beberapa tabel operasional, informasi penjualan dapat disimpan dalam satu struktur yang lebih terorganisasi. Tabel fakta tersebut kemudian digunakan sebagai sumber utama pada Sales Mart untuk mendukung berbagai kebutuhan analisis penjualan berdasarkan

pelanggan, produk, maupun periode waktu tertentu.

2. Product Mart

Product Mart berfokus pada analisis performa produk dan kategori produk yang dijual pada platform e-commerce. Data mart ini memungkinkan perusahaan mengetahui produk atau kategori yang paling banyak memberikan kontribusi terhadap pendapatan. Product Mart dibangun menggunakan tabel fakta *fact_product* dan tabel dimensi *dim_product*.

Berikut ini adalah contoh query sql pada Sales Mart:

```
query_product = """
    select
        oi.order_id,
        oi.product_id,
        oi.price,
        oi.freight_value,
        o.purchase_year,
        o.purchase_month,
        o.purchase_day
    from order_items oi
    join orders o
        on oi.order_id = o.order_id"""

fact_product = pd.read_sql(query_product, dw)
fact_product.head()
```

Query tersebut digunakan untuk mengambil data transaksi produk dari tabel *order_items* dan menggabungkannya dengan informasi waktu pembelian yang terdapat pada tabel *orders*. Hasil dari query ini membentuk tabel fakta (*fact_product*) yang memuat informasi mengenai produk yang terjual, harga produk, biaya pengiriman, serta waktu transaksi. Data yang telah terintegrasi tersebut memungkinkan seluruh informasi terkait produk tersimpan dalam satu tabel yang lebih terstruktur dan mudah dianalisis. Tabel fakta ini kemudian digunakan sebagai sumber utama pada Product Mart untuk mendukung analisis performa produk, kategori produk, serta kontribusi produk terhadap penjualan secara keseluruhan.

3. Logistic Mart

Logistic Mart digunakan untuk menganalisis aktivitas pengiriman dan distribusi produk kepada pelanggan. Data mart ini menyediakan informasi mengenai biaya pengiriman, waktu pembelian, tanggal pengiriman aktual, serta estimasi waktu pengiriman. Logistic Mart dibangun menggunakan tabel fakta *fact_logistic* dan tabel *dimensi dim_customer.*

Berikut ini adalah contoh query sql pada Logistic Mart:

```
query_logistic = """
    select
        oi.order_id,
        c.customer_id,
        oi.freight_value,
        o.order_purchase_timestamp,
        o.order_delivered_customer_date,
        o.order_estimated_delivery_date
```

```
    from order_items oi
    join orders o
        on oi.order_id = o.order_id
    join customers c
        on o.customer_id = c.customer_id"""

fact_logistic = pd.read_sql(query_logistic, dw)
fact_logistic.head()
```

Query tersebut digunakan untuk mengambil data yang berkaitan dengan proses pengiriman dan menggabungkan informasi dari tabel *order_items*, *orders*, dan *customers*. Hasil dari query ini membentuk tabel fakta (*fact_logistic*) yang memuat informasi mengenai pesanan, pelanggan, biaya pengiriman, waktu pembelian, tanggal pengiriman aktual kepada pelanggan, serta tanggal estimasi pengiriman. Data yang telah terintegrasi tersebut memungkinkan seluruh informasi terkait aktivitas logistik tersimpan dalam satu tabel yang lebih terstruktur dan mudah dianalisis. Tabel fakta ini kemudian digunakan sebagai sumber utama pada Logistic Mart untuk mendukung analisis biaya pengiriman, ketepatan waktu distribusi, serta evaluasi kualitas layanan pengiriman kepada pelanggan.

D. Contoh Query dan Analisis Temuan

1. Total Revenue Keseluruhan

```
cube.query(m["Revenue"])
```

Query ini digunakan untuk melihat total pendapatan keseluruhan dari seluruh transaksi pada dataset Olist. Measure Revenue dihitung menggunakan agregasi sum(price) pada tabel order_items. Hasil query ini dapat digunakan sebagai indikator utama performa penjualan pada data warehouse.

2. Revenue Berdasarkan Kategori Produk

```
cube.query(m["Revenue"], levels=[l["product_category_name"]])
```

Query ini digunakan untuk menganalisis kontribusi revenue berdasarkan kategori produk. Dengan adanya dimensi produk, sistem dapat mengelompokkan total revenue pada setiap kategori produk. Hasil query dapat digunakan untuk mengidentifikasi kategori produk dengan nilai transaksi tertinggi.

3. Total Order Berdasarkan Wilayah Customer

```
cube.query(m["Total_Order"],
levels=[l["customer_state"], l["customer_city"]])
```

Query ini digunakan untuk melihat distribusi jumlah transaksi berdasarkan lokasi pelanggan. Data dikelompokkan berdasarkan state dan city customer sehingga dapat diketahui wilayah dengan jumlah order tertinggi. Informasi ini dapat digunakan untuk melihat persebaran pelanggan pada dataset.

4. Revenue Berdasarkan Waktu Transaksi

```
cube.query(m["Revenue"],
levels=[l["purchase_year"], l["purchase_month"]])
```

Query ini digunakan untuk menganalisis perubahan revenue berdasarkan waktu transaksi. Pengelompokan berdasarkan tahun dan bulan memungkinkan analisis tren transaksi pada periode tertentu. Query ini memanfaatkan atribut hasil feature engineering timestamp pada proses ETL.

5. Total Freight Berdasarkan Wilayah Customer

```
cube.query(m["Total_Freight"],
```

```
levels=[l["customer_state"]])
```

Query ini digunakan untuk melihat total biaya pengiriman berdasarkan wilayah pelanggan. Measure *Total_Freight* dihitung menggunakan agregasi *sum(freight_value)* pada tabel transaksi. Hasil query dapat digunakan untuk membandingkan distribusi biaya pengiriman antar wilayah customer.

BAB 5 Kesimpulan

Dari proyek ini, data Olist E-Commerce yang awalnya masih tersebar di beberapa tabel sudah berhasil disusun menjadi data yang lebih mudah dianalisis. Data seperti customers, orders, order_items, payments, products, dan sellers diproses melalui tahap ETL, mulai dari membaca data, mengecek masalah data, menangani nilai kosong, memperbaiki tipe data tanggal, menyamakan beberapa penulisan data, sampai menyimpan data ke database. Setelah proses tersebut, data menjadi lebih tertata dan bisa digunakan untuk membuat data mart serta analisis OLAP.

Data Warehouse pada proyek ini dibuat dengan pendekatan data mart, yaitu Sales Mart, Product Mart, dan Logistic Mart. Sales Mart digunakan untuk melihat transaksi penjualan, Product Mart digunakan untuk menganalisis performa produk dan kategori produk, sedangkan Logistic Mart digunakan untuk melihat data pengiriman. Pembagian ini membuat analisis menjadi lebih terarah karena setiap data mart memiliki fokus yang berbeda sesuai kebutuhan bisnis.

Dari hasil measure pada cube, total revenue yang diperoleh sebesar 13.591.643,70 dengan total order sebanyak 98.666 transaksi. Nilai ini menunjukkan bahwa data warehouse yang dibuat sudah dapat memberikan gambaran umum mengenai performa penjualan pada dataset Olist. Selain itu, measure lain seperti Total Freight dan Average Revenue juga membantu melihat biaya pengiriman serta rata-rata nilai penjualan per item produk.

Melalui analisis cube, data juga dapat dilihat dari beberapa sisi, seperti kategori produk, wilayah customer, waktu transaksi, dan biaya pengiriman berdasarkan wilayah. Dengan cara ini, perusahaan dapat mengetahui bagian mana yang memberi kontribusi besar terhadap penjualan, bagaimana persebaran transaksi pelanggan, serta bagaimana biaya pengiriman berbeda antar wilayah. Informasi seperti ini dapat digunakan sebagai dasar untuk menentukan strategi promosi, pengelolaan produk, dan evaluasi layanan logistik.

Secara keseluruhan, proyek ini menunjukkan bahwa Data Warehouse dan OLAP cube dapat membantu mengubah data transaksi yang masih mentah menjadi informasi yang lebih mudah dipahami. Hasil analisis tidak hanya menjelaskan total penjualan, tetapi juga membantu melihat pola bisnis dari sisi produk, pelanggan, waktu, dan pengiriman. Untuk pengembangan selanjutnya, analisis dapat ditambah dengan data review pelanggan atau measure tambahan seperti Average Delivery Time dan Revenue Growth agar hasil analisis menjadi lebih lengkap.

Daftar Pustaka

Akter, S., & Wamba, S. F. (2016). Big data analytics in e-commerce: A systematic review and agenda for future research. Electronic Markets, 26(2), 173–194. https://link.springer.com/article/10.1007/s12525-016-0219-0

Doutreligne, M., Degremont, A., Jachiet, P.-A., Lamer, A., & Tannier, X. (2023). Good practices for clinical data warehouse implementation: A case study in France [Preprint]. arXiv. https://arxiv.org/abs/2302.07074

Gunasekaran, A., Papadopoulos, T., Dubey, R., Wamba, S. F., Childe, S. J., Hazen, B., & Akter, S. (2017). Big data and predictive analytics for supply chain and organizational performance. Journal of Business Research, 70, 308–317. https://www.sciencedirect.com/science/article/abs/pii/S014829631630491X

Kathiravelu, P., Sharma, A., Galhardas, H., Van Roy, P., & Veiga, L. (2018). On-demand big data integration: A hybrid ETL approach for reproducible scientific research [Preprint submitted to the DMAH special issue of the Springer DAPD journal]. arXiv. https://arxiv.org/abs/1804.08985

Ren, S. J.-f., Wamba, S. F., Akter, S., Dubey, R., & Childe, S. J. (2017). Modelling quality dynamics, business value and firm performance in a big data analytics environment. International Journal of Production Research, 55(17), 5011–5026. https://www.tandfonline.com/doi/full/10.1080/00207543.2016.1154209